

二、研究計畫內容：

(一)摘要

隨著都市化的快速發展與人口持續增加，住宅需求不斷攀升，房價市場的變化成為當今社會關注的焦點。台北市作為台灣的首都，不僅是經濟與文化的核心，也是人口高度集中的地區。特別是在疫情後，台北市的房價市場表現更加熱絡。在科技業蓬勃發展及資金流動的推動下，房市價格屢創新高，如何準確預測房價不僅是學術研究的重要方向，也為消費者與政策制定者提供了重要參考依據。

由於近年來機器學習技術的興起，房價預測近年來已成為熱門研究主題之一。機器學習模型(如隨機森林、極限梯度提升)具備強大的擬合能力，能有效處理大量非線性與複雜特徵的數據。然而，這類模型在處理地理位置異質性與空間特性考量時仍存在一定的限制。為了解決此問題，部分研究開始將地理加權迴歸(geographically weighted regression; GWR)與機器學習結合，用以反應地區性差異。GWR 可解決空間異質性問題，針對不同地理位置進行建模分析，但其僅能描述房價的條件平均數，未能捕捉房價在不同分量(quantile)上的分布特性，對於全面理解市場動態存在局限。

本研究針對上述問題，基於台北市疫情後的房價數據，提出結合地理加權分量迴歸(geographically weighted quantile regression; GWQR)與堆疊集成(stacking ensemble)學習模型的方法。GWQR 能同時考量空間異質性與分量分布特性，揭示房價在不同分量下的空間分布；堆疊集成則整合多種機器學習模型的優勢，以提升預測的準確性與穩健性。本研究期望透過此創新方法，提升房價建模之靈活性，為房市變動提供全面洞察，並為相關決策提供進一步有用的訊息。

(二)研究動機與研究問題

隨著經濟結構的轉型及全球疫情的影響，台北市房價市場展現出顯著的區域差異。疫情後，隨著經濟活動逐步恢復，高科技產業布局深化，帶動大量高收入族群進駐，房地產需求隨之顯著增長，進一步推升房價。因此，研究疫情後的房市變化對於理解市場動態及未來趨勢尤為重要。房價作為都市發展與經濟規劃的重要指標，其準確預測成為近年來研究的熱門議題。然而，房價數據具有高度的空間異質性，不同地區因產業布局、人口結構與區域特性而存在顯著差異。在此背景下，如何有效結合地理空間特性進行高效預測，成為待解決的挑戰。透過結合空間分析與經濟變數的研究，不僅能揭示影響台北市房價的關鍵因子，也能為未來的城市規劃提供更精準的參考依據。

根據過去研究，機器學習技術因具備處理大規模數據與高效預測的能力，已被廣泛應用於房價預測，例如隨機森林(random forest)、極限梯度提升(XGBoost)及輕量化梯度提升 (LightGBM) 等模型能夠有效捕捉數據中的非線性關係與複雜特徵，並在房價預測上展現良好表現。然而，這些模型大多獨立運作，單一模型的預測能力仍受到其自身假設與學習方法的限制，因此近期開始有學者嘗試運用堆疊集成(stacking ensemble)技術來提升預測準確度(e.g. Srirutchataboon et al. 2021, Yang et al. 2023, Li et al. 2023, Vivekananda 2024)。堆疊集成技術透過整合多種機器學習模型，將不同模型的優勢互補，從而有效改善模型對複雜數據的適應能力和預測性能。

儘管堆疊集成技術已被成功應用於房價或租賃市場預測 (Hu and Tang 2023)，為相關研究提供了重要方向。但現有研究仍存在些許的侷限性。首先，由於不同地理區域的房價可能受到不同因素影響，傳統機器學習模型在空間層面上的解釋能力較弱，特別是在處理空間異質性問題上仍有不足。地理加權迴歸(geographically weighted regression; GWR)因考量地理空間位置對變數的影響，已成為空間資料分析中探討空間異質性的重要方法之一，並常被用於房價研究中。據我們所知，目前僅有少數研究嘗試將 GWR 與堆疊集成技術結合，以同時處理模型整合與空間異質性的問題。其次，在房價分析方法上，多數研究大都針對條件期望值或平均數進行分析，未考慮房價在不同分量下的分布特性，限制了對房價市場全貌的理解。最後，房價數據普遍呈現右偏分布(即高價房較低價房更具變異性)，單純關注平均數可能無法完整反映市場的異質性，尤其在高價房市場的分析上可能產生較大誤差。因此，在房價預測中引入不同分量的分析，可更完整地描述不同價格層級的市場行為，提升房價預測的穩健性。

基於上述研究現狀，本研究以台北市疫情後的房價數據為基礎，應用 Chen et al. (2012) 所提出的地理加權分量迴歸(geographically weighted quantile regression; GWQR)，並結合多種機器學習模型的堆疊集成技術，針對不同分量(0.25, 0.5, 0.75, 0.9)進行房價預測，以充分考量房價在不同分布特性下的空間異質性，期望提供更精確且全面的市場洞察。本研究的目標如下：

1. 探討堆疊集成技術是否有效提升 GWQR 模型的預測能力。
2. 分析房價分布在不同分位數下的空間異質性趨勢變化。
3. 釐清房價分布中的極端值特性，特別是高價房市場的空間集中性。
4. 利用多項評估指標比較本研究方法與單一傳統機器學習及地理加權迴歸相關方法的預測結果差異。

本研究期望能透過結合機器學習、空間分析與分量迴歸的創新方法，以補足現有

研究在探討空間異質性與價格分布特性上的不足。本研究將驗證結合 GWQR 與堆疊集成技術的優勢，以及其在房價分析的應用價值。最終，期望本研究結果能為城市規劃與房市決策提供科學依據，為房價預測方法的改進提供新的視角與方向。

(三) 文獻回顧與探討

近年來，隨著機器學習技術的迅速發展，其在房價預測領域的應用取得了顯著成果。傳統的統計模型(如多元回歸)在分析房價時通常假設數據間具有線性或簡單非線性關係，對高維數據與非線性特徵的處理能力較為有限。然而，房價受到多重複雜因素的影響，包括經濟條件、地理位置、人口結構及政策變動，變數間的相互作用具有高度非線性，使得傳統模型在處理這些數據時往往表現不佳。相較之下，機器學習技術因具備處理高維數據、擬合非線性關係及捕捉數據複雜特徵的能力，逐漸成為房價預測研究的主流方法。例如，隨機森林、梯度提升機(XGBoost、LightGBM)及深度學習模型(如卷積神經網絡 CNN)等技術已被廣泛應用於房價預測中(e.g., Wang et al., 2014; Schmidhuber et al., 2015; Xie et al., 2019; Islam et al., 2022; Li et al., 2023)。這些方法不僅能高效處理大量數據，還能自動識別並提取隱藏於數據中的重要特徵，為準確預測房價提供了技術支持。

在機器學習領域，單一機器學習模型往往受限於模型結構與參數設定，預測結果可能存在偏差。為提升預測能力，堆疊集成(Stacking)技術應運而生。堆疊集成是一種多層次的集成學習方法，其核心概念是將多個基礎模型(base models)的預測結果組合，再透過元學習器(meta learner)進行最終預測。這種方法不僅能夠結合不同模型的性能，在同一框架內協同工作，還可以通過元學習器進行優化組合，進一步減少預測的偏差與變異。與單一的聚合(bagging)技術(如隨機森林)和提升(boosting)方法(如 XGBoost、LightGBM)相比，堆疊集成透過多模型融合來提升預測的準確性與穩健性。近年來，堆疊集成技術逐漸被應用於房價預測領域，如 Truong et al. (2020)、Srirutchataboon et al. (2021)、Yang et al. (2023)、Li et al. (2023)、Vivekananda (2024)皆透過將 XGBoost、隨機森林、神經網路等模型作為基礎學習器，並使用線性回歸作為元學習器的堆疊集成架構分析數據。這些研究的結果顯示，堆疊集成技術可以顯著提高房價預測的準確度。

空間異質性是房價數據的重要特性，房價可能會因地理區域的特性(如交通便利性、環境質量等)呈現空間變異。現有的堆疊集成技術雖在房價預測領域存有優勢，卻多側重於全域預測，未充分考慮空間異質性問題，難以有效捕捉房價在研究區域內的空間變動情形。

在空間研究中，GWR 為分析空間異質性備受關注的方法。GWR 由 Brunsdon

et al. (1996)提出，其特點是將局部迴歸(local regression)與地理權重的概念加入傳統線性迴歸模式中，透過讓迴歸係數估計值隨空間位置變化的過程，具體地呈現變數關係的空間差異，進而解讀空間異質性的現象。GWR 因其結果易於解釋，已被廣泛用於各領域，而其在解釋地區房價差異方面也展現出重要價值 (e.g. Huang et al. 2010, Fotheringham and Park 2018)。然而，GWR 在處理大規模數據時計算成本較高，且難以捕捉非線性變數間的交互作用。為此，過去有文獻開始結合 GWR 與機器學習技術，進一步拓展房價分析的視角(Nkumane and Mlambo 2024)。最近，隨著堆疊集成技術的發展，Hu 與 Tang (2023) 提出了一種創新的方法，將 GWR 與堆疊集成技術結合，透過集成多種機器學習模型(隨機森林、XGBoost、LightGBM、CNN)的預測結果，並以 GWR 作為元學習器來捕捉數據的空間異質性。他們針對中國南京市的租屋市場進行實證研究，證實該方法相較於單一模型及其他集成方法具有更優異的預測表現。

Hu 與 Tang (2023) 的研究展現了結合 GWR 與堆疊集成技術做法的潛力，主要著重於條件平均數的預測。以房價資料為例，市場的多樣性與區域特性仍還需進一步關注不同價格層級的分布特性，如高價的市場及其空間分布情形。統計上，分量迴歸(quantile regression; QR)提供了一種有效工具，能夠探索數據在不同分量下的分布特徵，而不僅僅限於條件平均數的估計，且特別適用於分析數據中存在極端值的情況。一般而言，傳統 QR 缺乏對地理空間異質性的考慮，無法全面捕捉數據中隨地理位置變化的特性。基於此，Chen et al. (2012)提出 GWQR，將 GWR 與 QR 結合。此技術增加了 GWR 在空間分析的彈性，不僅能捕捉地理空間異質性，亦可針對不同分量進行討論；這使得 GWQR 在解釋房價數據的空間變化時可以更加全面 (Tomal and Helbich 2022)。

如同 GWR，單純使用 GWQR 可能在模型性能上存在限制，在處理多維、非線性特徵時仍面臨挑戰。因此，基於上述堆疊集成技術在房價分析上的優勢，我們認為將 GWQR 與堆疊集成技術結合，可成為解決房價預測中空間異質性與分布特性的創新方法。堆疊集成能通過整合多種機器學習模型(如 XGBoost、隨機森林、LightGBM、CNN 等)，發揮各模型的優勢，提升預測的準確性與穩健性。而將 GWQR 作為堆疊集成中的一部分，則可同時捕捉房價數據的空間異質性與分量特徵，進一步提升模型的解釋能力。

綜言之，機器學習與空間分析技術的結合在房價預測中具有潛力，而堆疊集成技術以其靈活性與模型融合能力，能顯著提升預測效能。雖然已有學者(如 Hu and Tang 2023)開始關注空間異質性問題，但相關研究仍然稀少，且僅關注於平均值，未能捕捉不同分位數下的房價變化。有鑑於此，本研究期望透過 GWQR

與堆疊集成技術的創新整合，提供更全面且精準的房價預測方法，並針對台北市疫情後的房價數據做深入分析，為房地產市場提供新的實證依據與參考，也為未來的房價預測研究開闢新的方向。

(四) 研究方法及步驟

本研究計畫將針對台北市疫情後的房價數據進行分析，透過結合 GWQR 與堆疊集成模型，探討不同分量下房價的空間異質性與預測能力，並與傳統機器學習模型進行比較分析。研究方法與步驟如下：

(1) 房價資料蒐集與變數彙整

臺灣新冠肺炎疫情於 2023 年 5 月 1 日由中央流行疫情指揮中心解編，防疫政策進入常態化管理階段，象徵疫情正式結束。本研究以 2023 年 5 月做為分界點，聚焦分析後疫情時期的台北房價市場變化，採用 2023 年 5 月至 2024 年 12 月作為樣本的研究期間。我們預計從內政部不動產交易實價查詢服務網、政府資料開放平台、內政部社會經濟資料庫等網站收集台北市各區的房價資料及相關變數。房價數據包含不同區域的交易價格、樓層、屋齡、建物類型與總坪數等。解釋變數部分則將參考相關文獻(e.g. 李佩臻 2023; 林彥辰 2018; 謝子宸 2018; 楊孝博 2011; 黃于祐 2007; 韓昕頻 2024; 鄭蓉 2020; 劉富容、游璿達、黃孝雲、劉正夫 2019; 鄧郁靜 2020; 黃允亭 2022; 陳敬筌 2019; 張怡文、江穎慧、張金鶚 2009)選取經濟(如區域平均所得、失業率等)、人口(如高收入族群比例、人口密度等)、環境(如空氣品質、氣溫、降水量等)與地理特徵(如距離捷運站、主要商圈與生活機能中心的距離等)等不同面向的來進行探討。資料蒐集完成後，我們將使用 Python 程式進行地址的經緯度轉換，將房地產及周邊設施的位置轉換為地理座標(緯度與經度)。所有數據將以地理資訊為基礎進行空間分析，並結合地圖圖層進行整合，最終以地圖視覺化方式呈現，為後續空間分析與模型建構提供基礎。

(2) 變數篩選

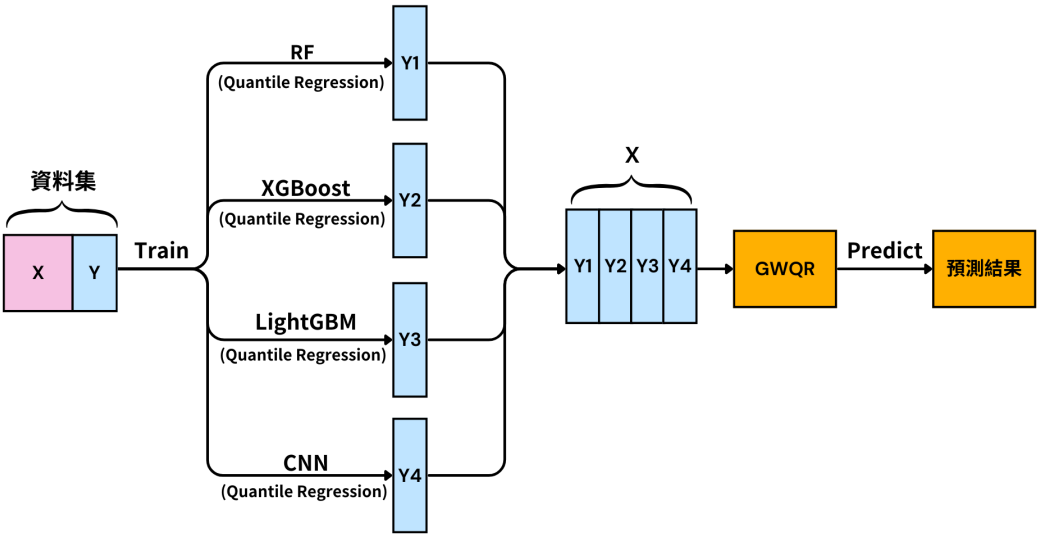
為提升模型訓練效率與預測性能，本研究預計考慮多種變數選擇方法，包括傳統統計方法與機器學習技術。例如，逐步迴歸(stepwise selection)與向後消去法(backward elimination)是常見的統計方法，透過計算變數對模型解釋力的影響，逐步加入或移除變數，以篩選出最佳變數組合，或亦參考 Hu and Tang (2023)所採用的遞迴特徵消除法(recursive feature elimination; RFE)，該方法透過機器學習模型(如隨機森林)評估變數重要性，並遞迴地移除影響較低的變數，以優化模型表現。透過綜合比較不同變數篩選方法的效果，本研究將選擇最適合的方式，以

確保模型的穩健性與解釋力。

(3) 堆疊集成模型分析

本研究將構建一個兩層式的堆疊集成模型，結合地理加權分量迴歸 GWQR 與多種機器學習模型，以更精細地捕捉房價的空間異質性與分量特徵。堆疊集成方法的核心在於將不同基礎模型(base learners)進行組合，並透過第二層的元學習器(meta learner)學習各基礎模型的預測結果，進一步提升整體預測效能。具體而言，第一層基礎模型會基於相同的輸入資料集進行獨立訓練，並產出初步的預測結果，這些結果將作為第二層的輸入特徵，再由元學習器進一步學習與優化最終的預測。

我們的第一層基礎學習器預計選擇四種在房價研究中常見的機器學習算法，包括隨機森林、極限梯度提升(XGBoost)、輕量化梯度提(LightGBM)和卷積神經網絡(CNN)。相較於 Hu 與 Tang (2023)的方法，我們在基礎學習器的目標與架構上進行了拓展與改進。Hu 與 Tang (2023)採用的基礎模型主要針對房價的條件期望值(即平均值)進行預測，而本研究的基礎學習器則針對四個不同的分量 (25%, 50%, 75%, 90%) 進行學習。這種設計能更全面地解析房價分布的特性，為高價與低價市場的分析提供更深入的洞察。此外，本研究的第二層元學習器預計採用 GWQR，充分結合空間異質性與分量迴歸的優勢，不僅能進一步捕捉房價的地理分布特性，還能提升對不同價格層級市場行為的解釋力。圖一展示了本研究堆疊集成模型與 GWQR 整合的流程圖，該架構在結構設計與功能實現上為房價預測提供了一個更彈性的分析架構。



圖一：堆疊集成 (stacking ensemble) 模型分析架構

● 第一層：基礎學習器 (base learners)

本研究將選擇四種在房價研究中常用的機器學習演算法作為基礎學習器，每個學習器均針對房價的不同分量進行訓練：

1. 隨機森林(random forest; RF)：基於多棵決策樹的集成學習方法，能處理能處理非線性關係並提供變數重要性評估。
2. 極限梯度提升(extreme gradient boosting; XGBoost)：一種基於梯度提升的演算法，常應用於房價預測，可處理缺失值問題。XGBoost 的逐步迭代特性使其對數據具有較強的適應能力，減少模型偏差。
3. 輕量化梯度提升(LightGBM)：與 XGBoost 相似，是一種改進型提升演算法，能高效處理大規模數據且具有較低計算成本。
4. 卷積神經網絡(convolutional neural network; CNN)：是一種深度學習模型，雖然多用於影像處理，但近年來也被應用於房價預測。CNN 能自動提取多層次特徵，捕捉非線性和局部模式。

我們預計將每個基礎模型的目標函數均設定為分量迴歸，針對四個分量(25%, 50%, 75%, 90%)進行獨立訓練。同時，所有基礎模型皆透過超參數調整，利用網格搜索(grid search)或貝葉斯優化(Bayesian optimization)策略與 K-fold 交叉驗證，逐一進行訓練與驗證，減少過擬合風險並提升模型穩健性。

● 第二層：元學習器 (meta learner)

本研究進一步拓展 Hu 與 Tang (2023)的概念，採用 GWQR 代替 GWR 作為元學習器，以綜合第一層基礎模型的預測結果，並在不同分位數下進行房價的空間異質性之分析。GWQR 可探討不同價格層級的房價分布特徵，並提供房價在空間上的趨勢變化。

GWQR 模型簡述

GWQR 基於分量迴歸，與 GWR 架構結合，以估計給定的分量 τ 的條件分布特徵，其數學形式如下 (Chen et al. 2012, Chen and Yang 2022)：

$$Y_i = \mathbf{X}_i^t \boldsymbol{\beta}_\tau(u_i, v_i) + \varepsilon_{\tau i}$$

其中 Y_i 表示第 i 個房屋物件的房價， $i = 1, 2, \dots, n$ ， (u_i, v_i) 為該物件之地理坐標， \mathbf{X}_i 輸入的解釋變數， $\varepsilon_{\tau i}$ 是 τ 分量 ($0 < \tau < 1$)的隨機誤差； $\boldsymbol{\beta}_\tau(u_i, v_i)$ 是相對應的局部分量迴歸係數。GWQR 的特點在於允許迴歸係數 $\boldsymbol{\beta}_\tau(u_i, v_i)$

隨地理位置 (u_i, v_i) 變化，其估計是通過最小化以下的損失函數：

$\sum_{j=1}^n \rho_\tau(Y_j - \boldsymbol{\beta}_\tau(u_i, v_i)) w_{ij}$ ，其中 $\rho_\tau(z) = z(\tau - I(z < 0))$ 為 check loss 函數，

$I(\cdot)$ 為指示變數； $w_{ij} = K(d_{ij}, h)$ 分配給每個觀測值的地理權重，由核函數 K 根據距離 d_{ij} 計算得出。距離 d_{ij} 是給定位置 (u_i, v_i) 與第 j 個位置 (u_j, v_j) 之間的距離。而核函數的範圍則由帶寬 h 調節，帶寬控制估計值的平滑程度，可選擇固定(fixed)或自適應(adaptvie)模式。通常，較接近 (u_i, v_i) 的觀測值會被賦予較高的權重，而距離較遠的觀測值則權重較低。核函數有多種選擇，詳情請參考 Fotheringham et al. (2002) 的描述。在文獻中，自適應雙平方核(adaptive bisquare kernel)函數最被廣泛使用。此外，本研究將沿用 Chen et al. (2012)，透過最小化交叉驗證誤差來確定最佳帶寬。

(4) 模型訓練流程：

1. 將訓練數據分為 K 份，進行 K -fold 交叉驗證，以提升模型的穩定性與可靠性。
2. 基礎模型基於相同的房價數據集進行獨立訓練，並產生針對不同分量($\tau = 0.25, 0.50, 0.75, 0.90$)的預測結果。
3. GWQR 使用第一層基礎模型的預測結果作為輸入特徵，結合地理坐標，進一步分析空間異質性並產生最終預測結果。

同時，本研究預計透過地圖視覺化工具(例如 ArcGIS 或 QGIS)，呈現不同分量下的房價分布結果。

本研究透過在堆疊集成模型中引入 GWQR，不僅增進模型對房價空間異質性的解析，也能針對不同房價層級提供更深入的預測結果。為驗證模型的有效性，我們將利用多項評估指標，如均方根誤差(root mean square error; RMSE)、分量損失和(total sum of check loss; Chen and Yang 2022)、pseudo- R^2 、對稱平均絕對百分比誤差 (symmetric Mean Absolute Percentage Error; sMAPE)、空間自相關性指標(Moran's I)等比較本研究模型與個別單一傳統機器學習方法、GWR、GWQR 的預測結果差異，進一步確保所提出方法的適用性。這些評估有助於驗證本研究方法在房價預測的優勢。

(5) 研究時間規劃

本研究計畫的執行進度如下：2025 年 7 月至 9 月閱讀相關文獻，9 月至 11 月蒐集資料，10 月至隔年 1 月資料分析與模式調整，12 月至隔年 2 月將資料視覺化，同時製作成果報告書。

	2025 年 7 月	2025 年 8 月	2025 年 9 月	2025 年 10 月	2025 年 11 月	2025 年 12 月	2026 年 1 月	2026 年 2 月
文獻回顧								
資料蒐集								
資料分析與模式調整								
資料視覺化								
製作成果報告書								

(五) 預期結果

隨著機器學習與深度學習的迅速發展，許多研究者開始嘗試將這些技術應用於解決各種空間分析問題，以提升模型的預測與解釋能力。而地理加權迴歸 (GWR) 作為研究空間異質性的常見方法之一，已有廣泛的應用。然而，隨著數據規模的快速成長及問題的日益複雜，傳統方法在處理非線性與高維數據時面臨瓶頸。因此，我希望結合本系所學與機器學習技術，透過引入 GWQR 模型以及 Stacking 堆疊學習的策略來改善現有方法的不足。在與本系長期研究空間分析的老師討論後，發現此方向仍有許多值得探索與優化之處，進而激勵我提出此研究計畫，以進行更深入的分析與研究。若計畫能順利通過，我預期能在參與的過程中得到如下成果：

1. 深入理解空間分析、GWR、GWQR 與機器學習的理論方法與應用
2. 熟悉 Stacking 模型設計框架與應用策略
3. 強化 Python、R 程式設計與分析技能
4. 熟悉 ArcGIS 或 QGIS 軟體操作與地圖視覺化的技巧
5. 提升跨領域研究與資料分析能力

我期望此研究能為台北市的城市規劃與房市決策提供新的視角與實務參考，並在機器學習與空間分析的結合應用上累積寶貴經驗。

(六) 需要指導教授指導內容

1. 深入理解 GWQR 模型與其應用策略

隨著機器學習與空間分析技術的發展，研究者開始探索如何有效處理空間異質性與高維數據的問題。然而，傳統地理加權迴歸模型在非線性關係處理上存在一定局限。因此，我希望透過這次研究深入理解 GWQR 的理論與應用。雖然大學課程涵蓋部分迴歸分析，但空間分析的實務經驗較少，特別是進階的 GWQR 技術更具挑戰性。系上陳怡如老師長期研究地理加權迴歸並應用於實務分析，我希望

在老師指導下，不僅理解 GWQR 理論，還能學習如何在實際數據中運用該模型，以提升解釋力與預測效果，進一步探索其在處理空間異質性資料方面的優勢與可能性。

2. 程式開發與機器學習模型優化

在與老師的討論過程中，我發現自己對空間資料分析的技巧與建模知識仍有不足，需更進一步了解與學習。本次研究計畫中，我預期使用 Python 與 R 程式語言來完成分析與模型構建。雖然課堂上有學習過相關的基礎程式能力，但尚未將其應用於實務經驗或研究計畫中。陳怡如老師在空間資料分析與實務應用上具有豐富的經驗，並熟悉使用各類分析工具與技術。藉由此次研究機會，我希望能向老師學習如何有效使用相關程式工具，進行資料處理與模型分析，掌握空間資料視覺化與分析技術，並提升程式設計的實務經驗，以成功完成研究計畫的分析任務。

3. 撰寫研究計劃與成果報告的技巧

在參考相關的研究成果報告與相關論文後，我發現自己在論述與表達方面仍有許多不足之處，特別是在將技術性內容轉化為清晰易懂的文字描述上，需要更多的練習與指導。由於陳怡如老師在學術論文撰寫與研究計畫撰寫方面經驗豐富，也有與不同領域學者合作的背景，因此我希望透過此次研究機會，向老師學習撰寫研究報告的技巧，包括如何有效地組織內容、簡化技術性敘述，使非專業讀者也能輕鬆理解研究成果。最終，我期望能完成一份具有專業水準、結構清晰且具說服力的研究報告。

(七) 參考文獻

1. Aziz, M.A.; Nurrahim, F.; Susanto, P.E.; Windiatmoko, Y. Boarding House Renting Price Prediction Using Deep Neural Network Regression on Mobile Apps. arXiv, 2020, arXiv:2101.02033.
2. Brunsdon, C.; Fotheringham, A.S.; Charlton, M.E. Geographically Weighted Regression: A Method for Exploring Spatial Nonstationarity. *Geographical Analysis*, 1996, 4, 281–298.
3. Chen, V.Y.J.; Deng, W.S.; Yang, T.C.; Matthews, S.A. Geographically Weighted Quantile Regression (GWQR): An Application to U.S. Mortality Data. *Geographical Analysis*, 2012, 44(2), 134–150.

4. Das, S.S.S.; Ali, M.E.; Li, Y.F. et al. Boosting House Price Predictions Using Geo-Spatial Network Embedding. *Data Min Knowl Disc*, 2021, 35, 2221–2250.
5. Huang, B.; Wu, B.; Barry, M. Geographically and Temporally Weighted Regression for Modeling Spatio-Temporal Variation in House Prices. *International Journal of Geographical Information Science*, 2010, 24(3), 383–401.
6. Hu, G.; Tang, Y. GERPM: A Geographically Weighted Stacking Ensemble Learning-Based Urban Residential Rents Prediction Model. *Mathematics*, 2023, 11(14), 3160.
7. Islam, M.D.; Li, B.; Islam, K.S.; Ahasan, R.; Mia, M.R.; Haque, M.E. Airbnb Rental Price Modeling Based on Latent Dirichlet Allocation and MESF-XGBoost Composite Model. *Learn. Appl.*, 2022, 7, 100208.
8. Kang, Y.; Zhang, F.; Peng, W.; Gao, S.; Rao, J.; Duarte, F.; Ratti, C. Understanding House Price Appreciation Using Multi-Source Big Geo-Data and Machine Learning. *Land Use Policy*, 2021, 111, 104919.
9. Lei, Y.T. Prediction of House Prices of Hardcover Houses Based on Regression Model Integration. Master's Thesis, Lanzhou University, Lanzhou, China, 2020.
10. Li, H.; Lin, H.; Jia, Y. Predicting the Trend of Rental Housing Prices in Shenzhen Based on Stacking Regression Models. *Proceedings of the 5th International Conference on Economic Management and Model Engineering (ICEMME 2023)*, 2023, 73.
11. Li, Y.; Branco, P.; Zhang, H. Imbalanced Multimodal Attention-Based System for Multiclass House Price Prediction. *Mathematics*, 2023, 11, 113.
12. Liang, R. Based on Machine Learning Model Research on Housing Rent in Shenzhen. Master's Thesis, Huazhong Normal University, Wuhan, China, 2020.
13. Lin, Y.-R.; Chen, C.-C. House Price Prediction in Taipei by Machine Learning Models. *International Journal of Design, Analysis and Tools for Integrated Circuits and Systems*, 2019, 1, 89–94.
14. Liu, S.Y. Machine Learning Methods for Analyzing the Influencing Factors of Urban Rental Prices. Master's Thesis, Nankai University, Tianjin, China, 2021.
15. Nkumane, A.; Mlambo, F. Comparative Analysis of Geographically Weighted Regression, Artificial Neural Networks and Random Forests for Modelling House Prices. *Wits Global Fintech Conference*, 2024, 10.13140/RG.2.2.11374.42563.

16. Schmidhuber, J. Deep Learning in Neural Networks: An Overview. *Neural Netw.*, 2015, 61, 85–117.
17. Sibindi, R.; Mwangi, R.W.; Waititu, A.G. A Boosting Ensemble Learning-Based Hybrid Light Gradient Boosting Machine and Extreme Gradient Boosting Model for Predicting House Prices. 2022.
18. Stewart, Fotheringham, A.; Park, B. Localized Spatiotemporal Effects in the Determinants of Property Prices: A Case Study of Seoul. *Applied Spatial Analysis and Policy*, 2018, 11, 581–598.
19. Srirutchataboon, G.; Prasertthum, S.; Chuangsuwanich, E.; Pratanwanich, P.N.; Ratanamahatana, C. Stacking Ensemble Learning for Housing Price Prediction: A Case Study in Thailand. *Proceedings of the 2021 13th International Conference on Knowledge and Smart Technology (KST)*, 2021, 73–77.
20. Tang, X.B.; Zhang, R.; Liu, L.X. Research on Prediction of Second-Hand House Prices in Beijing Based on Bat Algorithm SVR Model. *Res.*, 2018, 35, 71–81.
21. Tomal, M.; Helbich, M. A Spatial Autoregressive Geographically Weighted Quantile Regression to Explore Housing Rent Determinants in Amsterdam and Warsaw. *Environment and Planning B: Urban Analytics and City Science*, 2022, 23998083221122790.
22. Truong, Q.; Nguyen, M.; Dang, H.; Mei, B. Housing Price Prediction via Improved Machine Learning Techniques. *Procedia Comput. Sci.*, 2020, 174, 433–442.
23. Vivekananda, M.N.; Shidlyali, P.A. Enhancing Housing Price Prediction Using AI and Machine Learning: A Stacked Regression Meta-Modeling Approach. *Proceedings of the 2024 8th International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, 2024, 1954–1960.
24. Wang, P.Y.; Chen, C.T.; Su, J.W.; Wang, T.Y.; Huang, S.H. Deep Learning Model for House Price Prediction Using Heterogeneous Data Analysis Along with Joint Self-Attention Mechanism. *IEEE Access*, 2021, 9, 55244–55256.
25. Wang, X.; Wen, J.; Zhang, Y.; Wang, Y. Real Estate Price Forecasting Based on SVM Optimized by PSO. *Optik*, 2014, 125, 1439–1445.
26. Wu, X. The XGBoost-Bagging Approach of Predicting House Prices. *Academic Journal of Computing & Information Science*, 2024, 7(4), 1–9.
27. Xie, Y.; Zhang, W.; Ji, M.Z.; Peng, J.; Huang, Y.H. Application Analysis of Housing Month Rent Prediction Based on XGBoost and LightGBM Algorithms. *Appl. Softw.*, 2019, 36, 151–155.

28. Yang, Z.; Zhu, X.; Zhang, Y.; Nie, P.; Liu, X. A Housing Price Prediction Method Based on Stacking Ensemble Learning Optimization Method. Proceedings of the 2023 IEEE 10th International Conference on Cyber Security and Cloud Computing (CSCloud) / 2023 IEEE 9th International Conference on Edge Computing and Scalable Cloud (EdgeCom), 2023, 96–101.
29. Zhang, X.Y. Rent Prediction Based on Stacking Regression Model and Baidu Map API. Master's Thesis, Lanzhou University, Lanzhou, China, 2022.
30. 李佩臻 (2023)。應用集成學習建立房價預測模型 – 以台北市為例〔碩士論文，中原大學〕。華藝線上圖書館。
31. 林彥辰 (2018)。地理加權分量迴歸於登革熱風險指標之分析〔碩士論文，淡江大學統計學系應用統計學碩士班〕。
32. 張怡文、江穎慧、張金鶚 (2009)。分量迴歸在大量估價模型之應用—非典型住宅估價之改進。都市與計劃，36(3)，281-304。
33. 楊孝博 (2011)。鐵路車站旅客運輸需求之實證性研究-地理加權迴歸之應用〔碩士論文，國立臺灣大學地理環境資源學系〕。
34. 黃于祐 (2007)。台北市房價影響因素之空間分析-地理加權迴歸方法之應用〔碩士論文，國立臺北大學〕。華藝線上圖書館。
35. 黃允亭 (2022)。應用實價登錄建立以聚類方法之堆疊泛化房價預測模型——以桃園市區分建物房價資料為例〔碩士論文，國立政治大學〕。政大機構典藏。
36. 韓昕頻 (2024)。半參數地理加權貝它迴歸模型之建立與應用〔碩士論文，國立政治大學〕。臺灣博碩士論文知識加值系統。
37. 陳敬筌 (2019)。應用深度學習預測區域住房平均價格—以台北市實價登錄為例〔碩士論文，銘傳大學資訊管理學系碩士在職專班〕。
38. 鄭蓉 (2020)。捷運場站對地價影響的空間尺度效應研究—以高雄捷運紅線為例〔碩士論文，國立成功大學〕。臺灣博碩士論文知識加值系統。
39. 劉富容、游璿達、黃孝雲、劉正夫 (2019)。利用政府開放資料探討影響台北市房價之主要房屋特性及周邊設施影響因子。
40. 謝子宸 (2018)。考慮住宅周邊環境之房價預測分析模型及服務系統 — 以台北市與新北市為例〔碩士論文，國立交通大學〕。華藝線上圖書館。
41. 鄧郁靜 (2020)。應用深度學習於房價預測模型之研究〔碩士論文，國立交通大學〕。臺灣博碩士論文知識加值系統。